Análise Comparativa de Arquiteturas de Deep Learning (Stacked LSTM vs. 1D-CNN) no Reconhecimento de Atividades Humanas

Ramon Lima de Oliveira Tavares

2025-07-12

1 Introdução

O monitoramento automático de atividades humanas (HAR - *Human Activity Recognition*) consolidou-se como um vetor de inovação na computação onipresente e saúde digital (Lara & Labrador, 2013). Sensores inerciais miniaturizados, integrados massivamente em *smartphones* e *wearables*, geram fluxos de dados contínuos que, quando processados por algoritmos inteligentes, permitem a inferência de comportamentos complexos.

A problemática central deste domínio reside na natureza estocástica, ruidosa e dependente do tempo das séries geradas pelo movimento humano. Enquanto métodos clássicos dependem de *feature engineering* manual, o Aprendizado Profundo (*Deep Learning*) oferece a capacidade de aprender representações hierárquicas diretamente dos dados brutos (LeCun et al., 2015).

Este trabalho propõe um estudo comparativo rigoroso entre duas arquiteturas de redes neurais profundas: as **Redes Neurais Convolucionais Unidimensionais (1D-CNN)**, especializadas em extração de padrões locais (Kiranyaz et al., 2021), e as **Redes Neurais Recorrentes (Stacked LSTM)**, especializadas em dependências temporais (Hochreiter & Schmidhuber, 1997). O objetivo é avaliar a eficácia preditiva, a eficiência de parâmetros e as limitações físicas de cada topologia utilizando o *dataset* UCI HAR.

2 Fundamentos Teóricos e Metodológicos

2.1 Descrição e Natureza dos Dados (UCI HAR)

O estudo utiliza dados de 30 voluntários realizando Atividades de Vida Diária (ADL) com um *smartphone* na cintura. A amostragem ocorreu a 50Hz (Anguita et al., 2013).

Figura 1: Sistema de Coordenadas do Smartphone para HAR

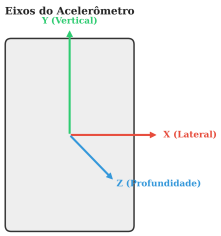

Fonte: Adaptado de Anguita et al. (2013).

A entrada da rede é um tensor de dimensão $(N, 128, 9)$, onde N é o número de amostras, 128 são os passos de tempo (2,56s) e 9 são as variáveis dinâmicas: 1. **Aceleração Corporal (Acc_{XYZ}^{body}):** 3 canais. Componente de movimento do usuário. 2. **Aceleração Total (Acc_{XYZ}^{total}):** 3 canais. Inclui a gravidade, crucial para distinguir posturas estáticas. 3. **Velocidade Angular ($Gyro_{XYZ}$):** 3 canais. Rotação do tronco.

2.2 Pré-processamento: Codificação One-Hot

Para viabilizar o treinamento supervisionado, os rótulos categóricos foram convertidos via **One-Hot Encoding**.

Tabela 1: Mapeamento de Classes e Codificação One-Hot

ID Original	Atividade	Índice Python	Vetor One-Hot (Target)
1	**Caminhando**	0	`[1, 0, 0, 0, 0, 0]`
2	**Subindo Escadas**	1	`[0, 1, 0, 0, 0, 0]`
3	**Descendo Escadas**	2	`[0, 0, 1, 0, 0, 0]`
4	**Sentado**	3	`[0, 0, 0, 1, 0, 0]`
5	**Em Pé**	4	`[0, 0, 0, 0, 1, 0]`
6	**Deitado**	5	`[0, 0, 0, 0, 0, 1]`

Fonte: Elaborada pelo autor.

2.3 Classificação Probabilística (Softmax)

A camada de saída utiliza a função **Softmax** para transformar os *logits* z em probabilidades normalizadas. A probabilidade $P(y = i)$ da amostra pertencer à classe i é dada por:

$$\sigma(z)_i = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$$

Onde: * z_i: Logit (saída linear) do neurônio correspondente à classe i. * K: Número total de classes ($K = 6$ neste estudo). * e: Constante de Euler (base do logaritmo natural). * $\sum_{j=1}^{K} e^{z_j}$: Fator de normalização que garante que a soma das probabilidades seja 1.

A predição final é a classe com maior probabilidade: $\hat{y} = \text{argmax}(\sigma(z))$ (Goodfellow et al., 2016).

3 Modelagem Computacional e Arquiteturas

A implementação foi realizada via Keras/TensorFlow. Abaixo, detalha-se a configuração exata e o cálculo teórico de complexidade de cada modelo.

3.1 Arquitetura A: Stacked LSTM (Recorrente)

A rede utiliza duas camadas LSTM em série para extração profunda de tempo.

Cálculo Teórico de Parâmetros: A fórmula para LSTM é $P = 4 \times [h \times (h + x + 1)]$. * **LSTM 1 (128 units):** $4 \times [128 \times (128 + 9 + 1)] = 70.656$. * **LSTM 2 (64 units):** $4 \times [64 \times (64 + 128 + 1)] = 49.408$. * **Total Estimado:** ~124k parâmetros.

Tabela 2: Resumo da Arquitetura Stacked LSTM

Camada	Configuração	Inicialização Pesos	Dropout Rate	Output Shape	Parâmetros
LSTM 1	128 units, return_seq=True	He Normal	-	(None, 128, 128)	70.656
Dropout 1	-	-	0.3	(None, 128, 128)	0
LSTM 2	64 units, return_seq=False	He Normal	-	(None, 64)	49.408

Camada	Configuração	Inicialização Pesos	Dropout Rate	Output Shape	Parâmetros
Dropout 2	-	-	0.3	(None, 64)	0
BatchNormalization		-	-	(None, 64)	256
Dense 1	64 units, ReLU	He Normal	0.2	(None, 64)	4.160
Output	6 units, Softmax	Glorot Uniform	-	(None, 6)	390
Total					**124.870**

Fonte: Elaborada pelo autor com dados do Keras.

3.2 Arquitetura B: Pure 1D-CNN (Convolucional)

Utiliza três blocos de convolução progressiva seguidos de *Global Average Pooling* (GAP).

Cálculo Teórico de Parâmetros: A fórmula para Conv1D é $P = (k \times C_{in} \times F) + F$. * **Conv 1:** $(3\times9\times64)+64 = 1.792$. * **Conv 2:** $(3\times64\times128)+128 = 24.704$. * **Conv 3:** $(3\times128\times256)+256 = 98.560$. * **Total Estimado:** ~143k parâmetros.

Tabela 3: Resumo da Arquitetura 1D-CNN

Camada	Configuração	Inicialização Pesos	Dropout Rate	Output Shape	Parâmetros
Conv1D 1	64 filtros, k=3	He Normal	-	(None, 126, 64)	1.792
Conv1D 2	128 filtros, k=3	He Normal	-	(None, 61, 128)	24.704
Conv1D 3	256 filtros, k=3	He Normal	-	(None, 28, 256)	98.560
GAP	Global Average	-	0.5	(None, 256)	0
Dense 1	64 units, ReLU	He Normal	0.25	(None, 64)	16.448
Output	6 units, Softmax	Glorot Uniform	-	(None, 6)	390
Total	(Incluindo BNs)				**143.686**

Fonte: Elaborada pelo autor com dados do Keras.

3.3 Configuração de Hiperparâmetros e Treinamento

Para assegurar a reprodutibilidade e a robustez dos resultados, ambos os modelos foram submetidos a um protocolo de treinamento rigoroso, utilizando técnicas de regularização como Dropout (Srivastava et al., 2014) e Batch Normalization (Ioffe & Szegedy, 2015).

Tabela 4: Hiperparâmetros e Estratégia de Otimização

Parâmetro	Configuração	Justificativa Teórica
Otimizador	Adam	Momento adaptativo (Kingma & Ba, 2014).
Taxa de Aprendizado (LR)	0.001 (Inicial)	Padrão para convergência estável.

Parâmetro	Configuração	Justificativa Teórica
Inicialização de Pesos	He Normal	Otimizada para ReLU (He et al., 2015).
Função de Perda	Categorical Crossentropy	Métrica para classificação multiclasse.
Critério de Parada	Early Stopping (Patience=12)	Previne overfitting ao monitorar validação.
Scheduler de LR	ReduceLROnPlateau	Ajuste fino em platôs de erro.
Batch Size	64 amostras	Estabilidade estocástica do gradiente.

Fonte: Elaborada pelo autor.

4 Aplicação e Análise de Resultados

4.1 Dinâmica de Treinamento

A Figura 2 ilustra a convergência. A **1D-CNN (C-D)** converge mais rapidamente que a **LSTM (A-B)** nas primeiras épocas, estabilizando com uma acurácia elevada, enquanto a LSTM exige mais épocas para refinar as dependências temporais.

Figura 2: Painel de Desempenho (Treino vs Validação)

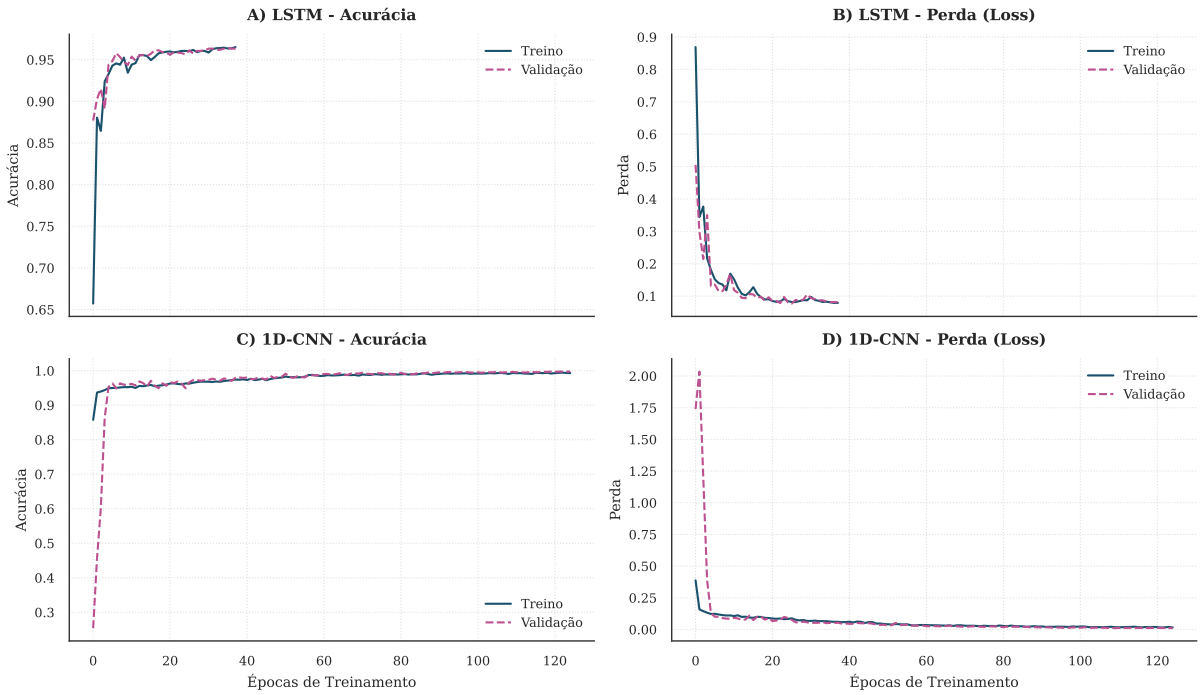

Legenda: A-B: Stacked LSTM; C-D: Pure 1D-CNN. Linhas sólidas: Treino; Tracejadas: Validação.
Fonte: Elaborada pelo autor.

4.2 Avaliação Comparativa (Dados de Teste)

A robustez foi verificada no conjunto de teste (2.947 amostras).

4.2.1 Resultados: Stacked LSTM

O modelo recorrente atingiu uma acurácia global de **90%**.

Tabela 5: Métricas Detalhadas - Stacked LSTM

Classe	Precision	Recall	F1-Score	Suporte
Caminhando	0.98	0.92	0.95	496
Subindo	0.87	0.92	0.90	471
Descendo	0.86	1.00	0.92	420
Sentado	0.79	0.86	0.82	491
Em Pé	0.90	0.78	0.84	532
Deitado	**1.00**	**0.95**	**0.97**	537
Média	**0.90**	**0.90**	**0.90**	**2947**

Fonte: Elaborada pelo autor a partir dos resultados experimentais.

4.2.2 Resultados: Pure 1D-CNN

O modelo convolucional superou o recorrente, atingindo uma acurácia global de **93%**.

Tabela 6: Métricas Detalhadas - Pure 1D-CNN

Classe	Precision	Recall	F1-Score	Suporte
Caminhando	1.00	0.95	0.97	496
Subindo	0.95	0.96	0.96	471
Descendo	0.91	1.00	0.95	420
Sentado	0.89	0.80	0.84	491
Em Pé	0.87	0.91	0.89	532
Deitado	**1.00**	**1.00**	**1.00**	537
Média	**0.94**	**0.93**	**0.93**	**2947**

Fonte: Elaborada pelo autor a partir dos resultados experimentais.

4.3 Análise de Erros e Confusão

A análise das matrizes de confusão (Figura 3) revela as limitações físicas do sistema.

Figura 3: Matrizes de Confusão Comparativas (Normalizadas)

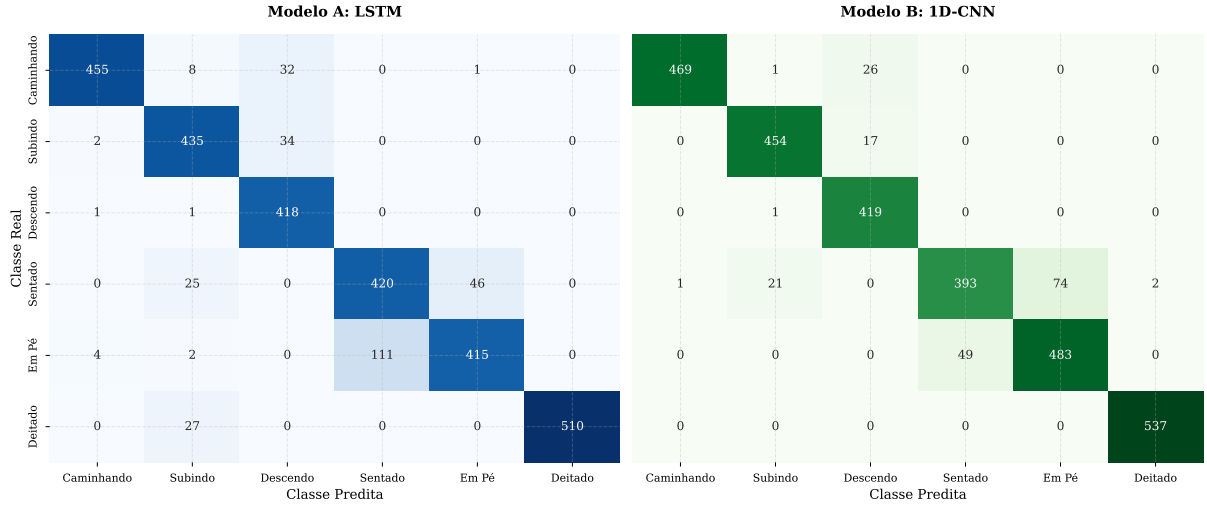

Legenda: Esquerda: Modelo LSTM; Direita: Modelo 1D-CNN.
Fonte: Elaborada pelo autor.

Discussão dos Resultados: 1. **Dinamismo:** Ambas as redes classificam com precisão quase perfeita movimentos cíclicos (Caminhar, Subir/Descer Escadas). 2. **O Dilema Estático:** A maior fonte de erro, visível em ambas as matrizes, é a confusão entre **"Sentado"** e **"Em Pé"**. * A LSTM teve maior dificuldade, com Precision de apenas 0.79 para "Sentado". * A CNN melhorou essa distinção (Precision 0.89), mas ainda confunde cerca de 20% das amostras. * *Causa:* Em repouso, a aceleração total aproxima-se da gravidade ($Acc \approx g$). Sem um barômetro para medir altitude, a orientação vetorial da gravidade é geometricamente idêntica nestas duas posturas (tronco ereto).

5 Conclusão

Este estudo comparou arquiteturas recorrentes e convolucionais para o reconhecimento de atividades humanas. A **1D-CNN** demonstrou superioridade sobre a **Stacked LSTM**, atingindo **93% de acurácia** (vs 90%) com uma convergência de treinamento mais estável e eficiente.

Apesar da CNN possuir um número ligeiramente maior de parâmetros totais (143k vs 124k), ela se beneficia da paralelização computacional e da capacidade de extrair assinaturas morfológicas locais (picos e formas de onda) que são altamente discriminativas em janelas curtas. A limitação persistente na distinção postural estática sugere a necessidade futura de fusão de sensores.

6 Referências

ANGUITA, D. et al. A Public Domain Dataset for Human Activity Recognition Using Smartphones. *ESANN 2013 proceedings*, Bruges, Belgium, 2013.

GERS, F. A.; SCHMIDHUBER, J.; CUMMINGS, F. Learning to forget: Continual prediction with LSTM. *Neural computation*, 12(10), 2451-2471, 2000.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning.* MIT Press, 2016.

HE, K. et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. *ICCV*, 2015.

HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780, 1997.

IOFFE, S.; SZEGEDY, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. *ICML*, 2015.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

KIRANYAZ, S. et al. 1D Convolutional Neural Networks and Applications: A Survey. *Mechanical Systems and Signal Processing*, 151, 2021.

LARA, O. D.; LABRADOR, M. A. A survey on human activity recognition using wearable sensors. *IEEE communications surveys & tutorials*, 15(3), 1192-1209, 2013.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, 521(7553), 436-444, 2015.

SRIVASTAVA, N. et al. Dropout: a simple way to prevent neural networks from overfitting. *The journal of machine learning research*, 15(1), 1929-1958, 2014.